M0373 - Llenguatges de marques i sistemes de gestió d'informació

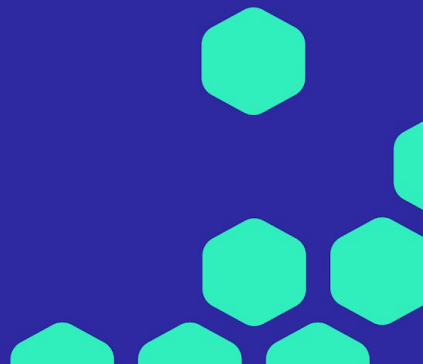
RA1 - Introducció als llenguatges de marques



Institut TIC
de Barcelona

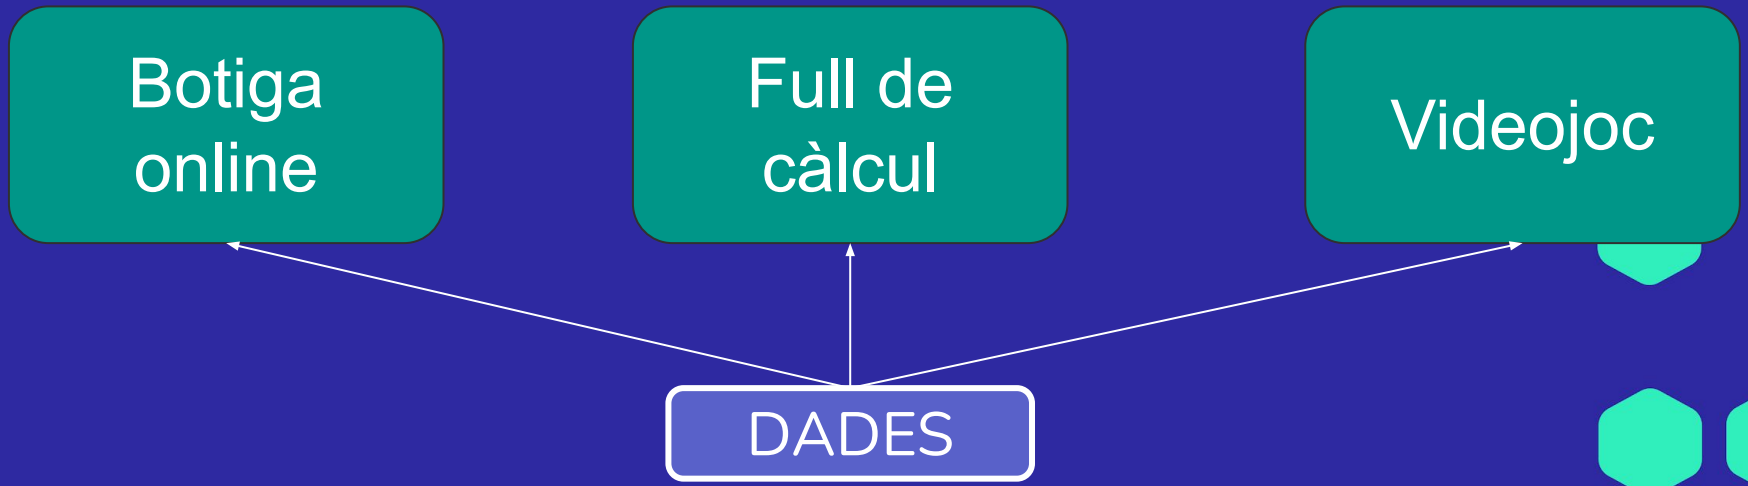
Índex

1. Introducció
2. Dades
3. Codificació
4. Comunicació
5. Llenguatge de marques



Introducció

Un dels **components bàsics** que necessita **un sistema informàtic** són les **dades**.



Introducció

Les dades són representacions d'aspectes del món real i se solen recollir per fer càlculs, mostrar-les, organitzar-les, etc., amb **l'objectiu que posteriorment se'n pugui fer algun ús:** prendre decisions, generar noves dades,...

Dades

Destinatari de dades:

- **Dades destinades als humans**
  - Generalment estructura concreta
  - Uns formats determinats
  - Amb textos decorats d'alguna manera

Sabem interpretar la informació

- **Dades destinades als programes**
  - Que siguin fàcilment identificables
  - Que quedi clar de quin tipus són

Necessita que li diguin com s'han d'interpretar les dades.

Dades

Destinades als humans

Avui. Dijous 30

	13 h	14 h	15 h	16 h	17 h	18 h	19 h	20 h	21 h	22 h	23 h
Cel											
Temperatura (°C)	20	20	21	21	21	21	21	21	21	20	19
Precipitació acumulada (mm)	0.3	0.8	0.3	0.3	0	0	0	0	0	0	0
Vent (km/h)	8	8	10	17	17	19	15	15	12	10	4

Destinades als programes

```
Data;Hora;Cel,Temperatura;Precipitació;Vent
Dijous 30; 13h; tempesta;20;0.3;8
Dijous 30; 14h; tempesta;20;0.8;8
Dijous 30; 15h; tempesta;22;0.3;10
Dijous 30; 16h; tempesta;22;0.3;17
Dijous 30; 17h; núvol;21;0;17
Dijous 30; 18h; núvol;21;0;19
Dijous 30; 19h; núvol;21;0;15
Dijous 30; 20h; núvol;21;0;15
Dijous 30; 21h; núvol;21;0;12
Dijous 30; 22h; núvol;20;0;10
Dijous 30; 23h; núvol;19;0;4
```

Comunicació

Els humans som capaços **d'interpretar diferents idiomes a través de diferents canals**: oral i escrit.

La màquina també és capaç d'interpretar la informació en diferents idiomes a través del que s'anomena **codificació**.

Comunicació

Per poder-nos comunicar amb la màquina utilitzarem **fitxers de text pla** on s'emmagatzema la informació lletra per lletra d'una manera similar a com ho faria un humà en escriure.

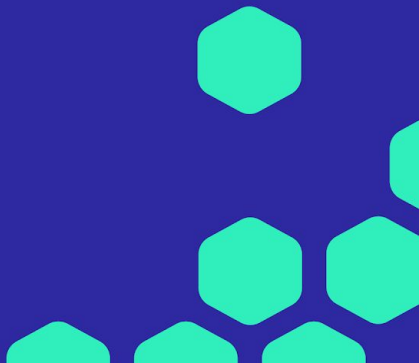
Llenguatge de Marques

- És un **llenguatge** que fa servir **etiquetes**.
- **Separa les dades de l'estructura i els estils**.
- Sorgeix de la necessitat **d'explotar informació** i **presentar-la de forma automatizada**.
- És necessari establir un **estàndard** per a la **comunicació**.

Llenguatge de Marques

Les **etiquetes** són una serie de conjunts de caràcters que s'incorporen als fitxers de text pla per definir:

- Format
- Organització
- Estructura



Llenguatge de Marques

Tipus de llenguatges de marques:

- Llenguatges procedimentals i de presentació
- Llenguatges descriptius o semàntics

Classificació dels Llenguatge de Marques

Llenguatges procedimentals i presentació

- Indiquen **COM s'han de presentar** les dades
- **HTML:** HyperText Markup Language





```
1  <!DOCTYPE html>
2  <html>
3  <head>
4  <title>Page Title</title>
5  </head>
6  <body>
7
8  <h1>Hello World</h1>
9  <p>Hola món</p>
10
11 </body>
12 </html>
```

Classificació dels Llenguatge de Marques

Llenguatges descriptius o semàntics

- Descriuen **l'estructura** lògica de les dades
  - **No indiquen com** representar-les

- El llenguatge de marques més conegut son **JSON**, **YAML i XML**

```json
{
  "string": "Hi",
  "number": 2.5,
  "boolean": true,
  "null": null,
  "object": { "name": "Kyle", "age": 24 },
  "array": ["Hello", 5, false, null, { "key": "value", "number": 6 }],
  "arrayOfObjects": [
    { "name": "Jerry", "age": 28 },
    { "name": "Sally", "age": 26 }
  ]
}
```

```xml
<?xml version="1.0"?>
<birds>
  <owl id="1201">
    <species>Bubo bubo</species>
    <name>Eagle Owl</name>
    <region>Eurasia</region>
  </owl>
  <owl id="1202">
    <species>Strix occidentalis</species>
    <name>Spotted Owl</name>
    <region>North America</region>
  </owl>
</birds>
```

Classificació dels Llenguatge de Marques

Classificació segons propòsit

Llenguatges de marques de propòsit general

- Defineixen regles genèriques, no etiquetes concretes
- Exemple: XML, JSON

Llenguatges de marques d'aplicació específica

- Vocabulari d'etiquetes ja definit per a un ús concret
- Exemple: HTML (web), SVG (gràfics), DocBook (documentació)

Avantatges dels Llenguatges de Marques

Per què utilitzar-los?

- Separen contingut, estructura i presentació
- Llegibles tant per humans com per màquines (text pla)
- Faciliten la interoperabilitat entre sistemes diferents
- Permeten estandardització: tothom "parla el mateix idioma"
- Faciliten el processament automàtic (cercar, validar, transformar)

Àmbits d’aplicació

On es fan servir?

- Web (HTML)
- Configuració d'aplicacions i sistemes (XML, YAML)
- Intercanvi de dades entre sistemes (XML, JSON)
- Publicació electrònica i documentació (DocBook, XML)
- Emmagatzematge estructurat de documents (Office Open XML, ODF)

Àmbits d'aplicació

Open

server_config.ini
~/codes/codes/ini vs yaml

```ini
[server]
port = 8080
host = 0.0.0.0

[logging]
level = info
file = /var/log/web-server.log

[database]
url = postgres://user:password@host:port/database
pool = 100
```

YAML

```html
<html>
    <head>
        <title>Simple Webpage</title>
    </head>
    <body>
        <p>Hello World!</p>
    </body>
    <footer>
        <p>CC</p>
    </footer>
</html>
```

HTML

temp : vim

File Edit View Bookmarks Settings Help

```docbook
<?xml version="1.0"?>
<book>
  <bookinfo>
    <title>An Example Book</title>
    <author>
      <firstname>Your first name</firstname>
      <surname>Your surname</surname>
      <affiliation>
        <address>
          <email>foo@example.com</email>
        </address>
      </affiliation>
    </author>
    <copyright>
      <year>2000</year>
      <holder>Copyright string here</holder>
    </copyright>
    <abstract>
      <para>If your book has an abstract then it should go here.</para>
    </abstract>
  </bookinfo>
  <preface>
    <title>Preface</title>
    <para>Your book may have a preface, in which case it should be placed here.</para>
  </preface>
```

DocBook

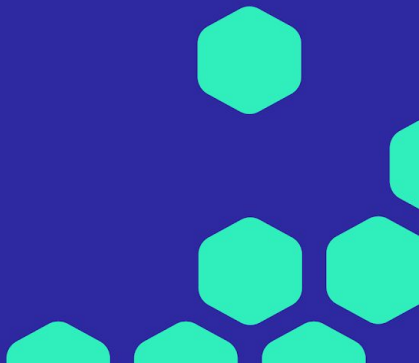
Office Open XML

```xml
<?xml version="1.0" encoding="UTF-8" standalone="yes"?>
<?mso-application progid="Word.Document"?>
<pkg:package
  <pkg:part pkg:name="/_rels/.rels"
  <pkg:part pkg:name="/word/_rels/document.xml.rels"
  <pkg:part pkg:name="/word/document.xml"
  <pkg:part pkg:name="/word/theme/theme1.xml"
  <pkg:part pkg:name="/docProps/thumbnail.emf"
  <pkg:part pkg:name="/word/settings.xml"
  <pkg:part pkg:name="/word/fontTable.xml"
  <pkg:part pkg:name="/word/webSettings.xml"
  <pkg:part pkg:name="/docProps/core.xml"
  <pkg:part pkg:name="/word/styles.xml"
  <pkg:part pkg:name="/docProps/app.xml"
  </pkg:package>
```

Regles sintàctiques bàsiques

Què vol dir que un document “està ben format”?

- Totes les etiquetes obertes s'han de tancar
- Les etiquetes s'han d'aniuar correctament (no encreuar-se)
- Ha d'existir un únic element arrel
- Distinció majúscules/minúscules (case-sensitive)
- Els valors d'atribut van entre cometes



Regles sintàctiques bàsiques

Per què importa?

- Un document mal format no es pot processar automàticament
- Els analitzadors (parsers) rebutgen documents no ben formats
- És la base perquè eines de validació, transformació i consulta funcionin

Espais de noms (namespaces)

Per què calen?

- Quan es combinen vocabularis de fonts diferents, poden coincidir noms d'etiquetes
- Exemple: un document que barreja dades de "llibres" i "pel·lícules", ambdós amb etiqueta <títol>
- L'espai de noms permet distingir-los sense ambigüitat

Espais de noms (namespaces)

Com es defineixen (exemple bàsic)?

- Es declaren amb un prefix i una URI identificadora
- Exemple senzill:

```
<llibre:títol>Contes</llibre:títol>

<peli:títol>El Padrino</peli:títol>
```

Eines d’edició

Amb què treballarem?

- Editors de codi: VS Code (el que farem servir al mòdul)
- Extensions útils: ressaltat de sintaxi, autocompletat, formatador
- Validadors en línia (per comprovar que un document és ben format / vàlid)
- Control de versions: Git + GitHub (ja el farem servir a RA02)